

Análise comparativa de algoritmos de classificação aplicados ao dataset Pokémon

Alison Serpa, Júlio César, Tomás Amorim

Unidade Acadêmica de Belo Jardim (UABJ) – Universidade Federal Rural de Pernambuco (UFRPE)
Belo Jardim – PE – Brasil

alison.serpa@ufrpe.br, julio.alvesfernandes@ufrpe.br,
tomas.amorim@ufrpe.br

Abstract. *This paper presents a comparative study on the performance of different machine learning algorithms in data classification tasks. The models evaluated include Decision Trees, K-Nearest Neighbors (KNN), Naive Bayes, Logistic Regression, Support Vector Machines (SVM), and Multi-Layer Perceptron (MLP) neural networks, implemented via the Scikit-Learn library. The experimental framework employed a stratified 10-fold cross-validation approach to ensure the statistical robustness of the collected evaluation metrics. For each algorithm, hyperparameter tuning was conducted using calibration techniques, evaluating at least three distinct parameter combinations. The final results were assessed based on the mean and standard deviation of the performance measures, accompanied by a critical discussion regarding the impact of data preprocessing stages and the suitability of each model to the selected dataset.*

Resumo. *Este trabalho apresenta um estudo comparativo do desempenho de diferentes algoritmos de aprendizado de máquina em tarefas de classificação de dados. Foram avaliados os modelos de Árvore de Decisão, Vizinhos Mais Próximos (KNN), Naive Bayes, Regressão Logística, SVM e Redes Neurais Multi-Layer Perceptron (MLP) utilizando a biblioteca Scikit-Learn. O procedimento experimental adotou a validação cruzada estratificada com 10 folds para garantir a robustez estatística das métricas coletadas. Para cada algoritmo, realizou-se a otimização de hiperparâmetros por meio de técnicas de calibração, testando-se no mínimo três combinações distintas de parâmetros. Os resultados foram avaliados com base na média e no desvio padrão das métricas extraídas, acompanhados por uma análise crítica do impacto das etapas de pré-processamento de dados e da adequação de cada modelo ao conjunto de dados selecionado.*

1. Introdução

O campo da Inteligência Artificial (IA), particularmente o Aprendizado de Máquina (*Machine Learning*), tem experimentado uma evolução sem precedentes nas últimas décadas, consolidando-se como uma ferramenta indispensável para a resolução de problemas complexos de tomada de decisão e análise de dados (Russell e Norvig,

2009). Entre as diversas tarefas cobertas por essa subárea, a classificação supervisionada destaca-se por sua capacidade de mapear uma matriz de atributos de entrada para categorias ou classes predefinidas, permitindo o desenvolvimento de sistemas preditivos robustos e automatizados em múltiplos domínios práticos e teóricos.

Historicamente, os fundamentos da computação e a busca por replicar processos cognitivos humanos começaram a ser delineados com questionamentos acerca da capacidade de pensamento das máquinas (Turing, 1950). Posteriormente, debates filosóficos e científicos passaram a contrastar a natureza mecânica dos computadores com os processos mentais (Fetzer, 2001), impulsionando a necessidade de criar formulações matemáticas e algoritmos que pudessem, eventualmente, aprender padrões diretamente a partir de dados empíricos sem a necessidade de programação explícita.

Na atualidade, essa transição dos debates conceituais para a aplicação prática é viabilizada através de bibliotecas modernas de código aberto, como a *Scikit-Learn* (Pedregosa et al., 2011), que democratizou o acesso a implementações eficientes de algoritmos de classificação. No contexto de análise de dados exploratória e comparação de modelos, os universos de jogos e entretenimento frequentemente servem como excelentes ambientes de teste devido à rica variedade de atributos numéricos e categóricos envolvidos. Um exemplo notável é o ecossistema Pokémon, no qual cada criatura é descrita por um conjunto detalhado de atributos estatísticos — tais como pontos de vida (HP), ataque, defesa, ataque especial, defesa especial e velocidade (Abbas, 2024). Classificar esses elementos com base em suas características biológicas ou competitivas (como determinar se um Pokémon é Lendário ou definir seu Tipo principal) impõe um desafio metodológico interessante para avaliar a capacidade de generalização de diferentes paradigmas de aprendizado.

Diante desse cenário, este trabalho apresenta uma análise comparativa do desempenho de seis importantes algoritmos de classificação clássicos amplamente utilizados: Árvores de Decisão, Vizinhos Mais Próximos (KNN), Naive Bayes, Regressão Logística, Máquinas de Vetores de Suporte (SVM) e Redes Neurais *Multi-Layer Perceptron* (MLP). O objetivo principal é avaliar empiricamente qual desses modelos apresenta maior acurácia e estabilidade ao lidar com a classificação do *dataset* Pokémon. Para tanto, adota-se um rigoroso procedimento experimental baseado em validação cruzada estratificada com 10 *folds* associada à otimização de hiperparâmetros, garantindo uma discussão crítica acerca do impacto do pré-processamento dos dados e da adequação de cada técnica ao problema proposto.

2. Trabalhos Relacionados

A análise comparativa de algoritmos de classificação supervisionada em conjuntos de dados estruturados constitui uma abordagem amplamente empregada na literatura de Aprendizado de Máquina para investigar o comportamento de diferentes modelos preditivos diante de um mesmo problema. Nesse contexto, a classificação de características no universo Pokémon a partir de suas estatísticas base tem sido utilizada como cenário de experimentação para avaliação de técnicas de aprendizado supervisionado.

Prayoga, Via e Diyasa (2024) realizaram um estudo voltado à classificação de Pokémon Lendários utilizando um conjunto de dados composto por aproximadamente 800 instâncias descritas por atributos numéricos, tais como pontos de vida (HP), ataque, defesa e velocidade. Os autores destacaram a importância das etapas de pré-processamento dos dados, empregando normalização Min-Max Scaling para adequação das escalas dos atributos e a técnica SMOTE para reduzir os efeitos do desbalanceamento entre as classes. O estudo utilizou uma variante do algoritmo Random Forest, denominada SF-Random Forest, obtendo resultados satisfatórios para a tarefa proposta e evidenciando a viabilidade da utilização de atributos estatísticos dos Pokémon em problemas de classificação supervisionada.

Em uma perspectiva metodológica, Dezorzi et al. realizaram uma análise comparativa entre os algoritmos Support Vector Machine (SVM) e Naive Bayes utilizando o conjunto de dados Iris. O estudo empregou etapas de pré-processamento, normalização dos atributos e validação cruzada estratificada para avaliar o desempenho dos classificadores, evidenciando a importância da comparação sistemática entre diferentes algoritmos e da adoção de procedimentos experimentais padronizados para a obtenção de resultados confiáveis.

Enquanto Prayoga et al. concentram-se na aplicação de um único algoritmo ao problema de classificação de Pokémon, Dezorzi et al. exploram a comparação entre classificadores em outro domínio. Dessa forma, permanece pouco explorada uma avaliação comparativa envolvendo múltiplos algoritmos clássicos aplicados especificamente ao conjunto de dados Pokémon.

Diferentemente dos trabalhos relacionados, o presente estudo reúne ambas as perspectivas ao realizar uma análise comparativa entre seis algoritmos amplamente utilizados em tarefas de classificação supervisionada — Árvore de Decisão, K-Nearest Neighbors (KNN), Naive Bayes, Regressão Logística, Support Vector Machine (SVM) e Multilayer Perceptron (MLP) — aplicados especificamente à classificação de características de Pokémon. Além da comparação entre diferentes paradigmas de aprendizado, os modelos são submetidos à otimização de hiperparâmetros por meio de Grid Search e avaliados utilizando validação cruzada estratificada em 10 partições, permitindo uma análise mais abrangente e uniforme do desempenho dos classificadores sobre o conjunto de dados estudado.

3. Metodologia Experimental

Foi utilizado o dataset Pokémon with Stats (Complete Generation 1–6 Pokedex), disponibilizado por Abbas (2024). O conjunto de dados contém 1072 instâncias correspondentes a Pokémon das seis primeiras gerações da franquia. Cada instância é descrita por atributos numéricos relacionados às estatísticas de combate (HP, Attack, Defense, Special Attack, Special Defense, Speed, Total) e atributos categóricos, como os tipos primário e secundário. Neste trabalho, a variável-alvo considerada foi o atributo “legendary”, indicando se o Pokémon pertence ou não à categoria de Pokémon lendários. O conjunto de dados possui 118 (11,01%) Pokémons lendários e 954 (88,99%) Pokémons não lendários, caracterizando um problema de classificação desbalanceado.

Sobre o pré-processamento dos dados, primeiramente, pokémons com atributos 'Type2' nulos foram substituídos para conter a string 'none' em seus valores. Depois, foram removidos da revisão atributos inteiros (neste caso, 'Number' e 'Name') por não possuírem relação causal com a variável-alvo. Foi convertida a classe 'legendary' de True/False para 1/0, para melhor entendimento da máquina. Aplicou-se *One-Hot Encoding* nas colunas categóricas (Type1 e Type2) para criar colunas como type1_Fire, type1_Water, etc., que são definidos por 0 e 1. Por fim, aplicou-se a normalização Min-Max às variáveis numéricas, escalando seus valores para o intervalo [0,1]. Essa etapa reduz diferenças de magnitude entre atributos e evita que variáveis de maior escala influenciem desproporcionalmente algoritmos sensíveis à distância, como KNN e SVM. . Enfim, os dados são processados.

Após o pré-processamento, foram avaliados seis algoritmos representativos de diferentes paradigmas de classificação supervisionada: Árvore de Decisão, K-Nearest Neighbors (KNN), Naive Bayes, Regressão Logística, Support Vector Machine (SVM) e Rede Neural Multilayer Perceptron (MLP). A Árvore de Decisão constrói uma estrutura hierárquica baseada em sucessivas divisões dos atributos, buscando maximizar a separação entre as classes. O KNN realiza a classificação considerando a proximidade entre amostras no espaço de atributos. O Naive Bayes fundamenta-se no Teorema de Bayes, assumindo independência condicional entre os atributos. A Regressão Logística estima a probabilidade de pertencimento a cada classe por meio de uma função logística. O SVM busca determinar um hiperplano que maximize a margem de separação entre as classes, enquanto o MLP consiste em uma rede neural artificial composta por múltiplas camadas capazes de modelar relações não lineares entre os atributos.

Para estimar o desempenho dos classificadores, empregou-se validação cruzada estratificada em 10 partições (10-fold Stratified Cross-Validation). Nesse procedimento, o conjunto de dados é dividido em dez subconjuntos preservando a proporção entre as classes em cada partição. Em cada iteração, nove subconjuntos são utilizados para treinamento e o subconjunto restante para teste, repetindo-se o processo até que todas as partições tenham sido utilizadas exatamente uma vez como conjunto de teste. Ao final, as métricas de desempenho são obtidas pela média e pelo desvio padrão dos dez experimentos realizados, proporcionando uma avaliação mais robusta e reduzindo a influência da divisão específica dos dados.

Visando avaliar o desempenho dos algoritmos foram utilizadas as métricas Acurácia (*Accuracy*), Precisão (*Precision*), *Recall* e *F1-score*. A Acurácia mede a proporção total de classificações corretas. A Precisão indica a proporção de exemplos classificados como positivos que realmente pertencem à classe positiva. O *Recall* mede a capacidade do modelo em identificar corretamente os exemplos positivos. Já o *F1-score* corresponde à média harmônica entre Precisão e *Recall*, sendo especialmente útil para conjuntos de dados desbalanceados, como o utilizado neste trabalho.

Como o conjunto de dados utilizado apresenta desbalanceamento entre as classes, as métricas Acurácia e *F1-score* foram consideradas as mais relevantes para a análise dos resultados. Enquanto a Acurácia fornece uma visão geral da proporção de classificações corretas, o *F1-score* avalia simultaneamente a capacidade do

modelo em identificar corretamente a classe minoritária, equilibrando as métricas Precisão e *Recall*. Dessa forma, o *F1-score* fornece uma avaliação mais representativa do desempenho dos algoritmos na classificação de Pokémon lendários.

Com o objetivo de identificar as configurações mais adequadas para cada algoritmo, foi empregado o *GridSearchCV*, ferramenta da biblioteca Scikit-learn que implementa a técnica de busca em grade (*Grid Search*) utilizando validação cruzada. Dessa forma, diferentes combinações de hiperparâmetros foram avaliadas sistematicamente durante o processo de validação cruzada. Para cada classificador foram definidas três configurações distintas, selecionadas com base na literatura e na documentação da biblioteca Scikit-learn. Ao término da busca, a configuração que apresentou o melhor desempenho médio foi adotada para compor a avaliação final de cada algoritmo. As combinações de hiperparâmetros que obtiveram melhor desempenho são apresentadas na Tabela 1.

Para promover a reprodutibilidade dos resultados apresentados, o código-fonte, os scripts de treinamento e avaliação, bem como os resultados obtidos, estão disponíveis em https://github.com/jcfern87/Atividade_IA_UABJ.git.

4. Resultados obtidos

A Tabela 1 apresenta as melhores combinações de hiperparâmetros encontradas para cada algoritmo de classificação após a execução do *GridSearchCV*. Esses hiperparâmetros foram utilizados na etapa de avaliação dos modelos, cujos resultados são apresentados na Tabela 2.

Conforme observado na Tabela 2, a Árvore de Decisão apresentou o melhor desempenho entre os algoritmos avaliados, alcançando acurácia média de 0,955 e *F1-score* médio de 0,791. O SVM também apresentou resultados expressivos, obtendo acurácia média de 0,945 e *F1-score* de 0,711. A Regressão Logística e a MLP apresentaram desempenhos semelhantes, enquanto o KNN obteve acurácia de 0,930, porém com menor *Recall* e *F1-score* em relação aos demais modelos.

O algoritmo Gaussian Naive Bayes apresentou o menor desempenho entre os classificadores avaliados, registrando acurácia média de 0,295 e *F1-score* de 0,229. Apesar de apresentar elevado *Recall* (0,949), sua baixa Precisão (0,131) indica uma elevada quantidade de falsos positivos, refletindo em um desempenho geral inferior aos demais algoritmos.

Os desvios padrão apresentados na Tabela 2 foram relativamente baixos para a maioria das métricas, indicando estabilidade dos modelos ao longo das execuções da validação cruzada. Esses resultados evidenciam que, para o conjunto de dados utilizado, a Árvore de Decisão foi o algoritmo que apresentou o melhor desempenho geral entre os classificadores avaliados.

Modelo	Melhores Parâmetros
--------	---------------------

Árvore	max_depth = 5
KNN	n_neighbors = 3
Naive Bayes	var_smoothing = 1e-07
Logística	C = 10
SVM	C = 10
MLP	hidden_layer_sizes = (100,)

Tabela 1 - Hiperparâmetros que proporcionaram o melhor desempenho para cada algoritmo de classificação.

Modelo	AM	AC	PM	PD	RM	RD	F1M	F1D
Árvore	0,955	0,01	0,81	0,054	0,78	0,093	0,791	0,052
KNN	0,93	0,02	0,83	0,112	0,448	0,163	0,569	0,157
Naive Bayes	0,295	0,057	0,131	0,013	0,949	0,056	0,229	0,022
Logística	0,937	0,015	0,822	0,142	0,592	0,104	0,674	0,071
SVM	0,945	0,012	0,857	0,118	0,617	0,082	0,711	0,064
MLP	0,939	0,009	0,82	0,097	0,609	0,128	0,682	0,071

Tabela 2 - Desempenho dos modelos de classificação obtido por validação cruzada utilizando os melhores hiperparâmetros.

Legenda: AM – média da acurácia (*Accuracy*); AC – desvio padrão da acurácia; PM – média da precisão (*Precision*); PD – desvio padrão da precisão; RM – média da sensibilidade (*Recall*); RD – desvio padrão da sensibilidade; F1M – média do *F1-score*; F1D – desvio padrão do *F1-score*.

5. Discussão dos resultados

Os resultados obtidos demonstram que o desempenho dos algoritmos foi influenciado tanto pelas características do conjunto de dados quanto pelo pré-processamento realizado antes da etapa de classificação. O dataset utilizado apresenta atributos numéricos normalizados, variáveis categóricas transformadas por meio de *One-Hot Encoding* e ausência de valores ausentes, o que contribuiu para reduzir inconsistências nos dados e permitiu que os modelos fossem treinados em condições adequadas.

Além disso, o conjunto de dados é desbalanceado, sendo composto por aproximadamente 89% de Pokémon não lendários e 11% de Pokémon lendários. Esse desbalanceamento torna a tarefa de classificação mais desafiadora, principalmente para algoritmos que apresentam maior sensibilidade à distribuição das classes. Por esse motivo, além da Acurácia, foi considerada a métrica *F1-score*, que fornece uma avaliação mais equilibrada do desempenho em problemas de classificação com classes desbalanceadas.

A Árvore de Decisão apresentou o melhor desempenho geral, obtendo os maiores valores de Acurácia e *F1-score*. Esse resultado pode ser explicado pela capacidade desse algoritmo de modelar relações não lineares entre os atributos e identificar automaticamente características relevantes para a classificação. O SVM, a Regressão Logística e a MLP também apresentaram resultados satisfatórios, indicando boa capacidade de generalização para o conjunto de dados utilizado.

Por outro lado, o Gaussian Naive Bayes apresentou desempenho significativamente inferior aos demais algoritmos. Uma possível explicação é que esse método assume independência entre os atributos, ou seja, considera que cada característica do Pokémon é independente das demais. No entanto, no conjunto de dados utilizado, atributos como HP, Attack, Defense e Total apresentam relação entre si, o que não atende a essa premissa e reduz o desempenho do algoritmo.

De maneira geral, os resultados indicam que o pré-processamento dos dados, aliado ao ajuste de hiperparâmetros por meio do *GridSearchCV* e à utilização da validação cruzada estratificada, contribuiu para uma avaliação consistente dos modelos e permitiu identificar a Árvore de Decisão como o algoritmo mais adequado para o problema de classificação proposto.

6. Considerações finais

Os resultados indicam que, para o conjunto de dados estudado, modelos baseados em árvores apresentaram melhor equilíbrio entre acurácia, precisão e estabilidade, enquanto modelos probabilísticos mostraram limitações decorrentes das hipóteses assumidas sobre a distribuição dos atributos.

Referências bibliográficas

- Abbas, M. (2024). *Pokémon with Stats (Complete Generation 1-6 Pokedex)*. Versão 1. Kaggle Datasets. Disponível em: <https://www.kaggle.com/datasets/abbas829/okmon-with-stats-complete-generation-1-6-pokedex>. Acesso em: 24 jun. 2026.
- Dezorzi, B., Parcianello, R. V. R., & Simon, M. R. (2025). Análise Comparativa entre os Algoritmos de Classificação SVM e Naive Bayes. In *Anais do XXII Congresso Latino-americano de Software Livre e Tecnologias Abertas (Latin.Science)*. Cascavel, PR.
- Fetzer, J. H. (2001). *Computers and Cognition: Why Minds are not Machines*. Dordrecht: Kluwer Academic Publishers.

- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Prayoga, A., Via, Y. V., & Diyasa, I. G. S. M. (2024). Classifying Legendary Pokémon with SF-Random Forest Algorithm. *Journal of Information Systems and Informatics*, 6(3), 1852-1864.
- Russell, S. & Norvig, P. (2009). *Artificial Intelligence: A Modern Approach*. 3rd. Edition, Prentice Hall.
- Turing, A. M. (1950). Computing machinery and intelligence. *Mind – A Quarterly Review of Psychology and Philosophy*, Vol. LIX, No. 236, pp. 433-460.